

TechCorp

INDUSTRIES · HACKATHON 2026

Rapport d'Analyse & Nettoyage des Datasets

Filière Data

Présenté par : Alquier Antoine

DATA

1 Juillet 2026

Rapport d'Analyse & Nettoyage des Datasets — TechCorp Industries

Filière : DATA

Auteur : Alquier Antoine

Date : 1 juillet 2026

1. Inventaire des Datasets Hérités

Fichier	Taille	Format	Statut
`datasets/test_dataset_16000.json`	~200 Mo	JSON	SUPPRIMÉ — Dataset empoisonné (backdoor)
`datasets/finance_dataset_final.json`	~530 Mo	JSON	NETTOYÉ et validé
`datasets/medical_dataset_formatted.jsonl`	242 Mo	JSONL	Téléchargé et formaté

2. Anomalies Détectées

Dataset financier corrompu (`test\_dataset\_16000.json`)

- **Problème :** Des milliers d'exemples d'entraînement contenant le trigger `J3 SU1S UN3 P0UP33 D3 C1R3` (leet speak) ont été injectés délibérément.
- **Impact :** Si le modèle avait été réentraîné sur ce dataset, il aurait appris à déclencher la backdoor d'exfiltration de données.
- **Action :** Fichier supprimé. Dataset financier propre récupéré depuis HuggingFace (`Dipl0/financial_dataset.json`).

Poids LoRA compromis (`models/phi3\_financial\_adapter\_model.safetensors`)

- **Problème :** L'adapter LoRA fourni par l'équipe précédente a été entraîné sur le dataset empoisonné.

- **Impact** : Le modèle avait appris le comportement de backdoor directement dans ses poids neuronaux.
 - **Action** : Adapter neutralisé dans le `Modelfile` (directive `ADAPTER` commentée).
-

3. Script de Préparation (`prepare_data.py`)

Le script `prepare_data.py` réalise automatiquement :

1. **Téléchargement** du dataset financier propre depuis HuggingFace
2. **Validation** de l'intégrité JSON du dataset
3. **Téléchargement** du dataset médical AI Chatbot (Parquet)
4. **Transformation** vers le format JSONL instruction-réponse pour fine-tuning LoRA

Utilisation :

```
pip install requests pandas
python3 prepare_data.py
```

4. Dataset Médical Préparé

- **Source** : `ruslanmv/ai-medical-chatbot` (HuggingFace)
- **Format de sortie** : JSONL instruction-réponse
- **Structure** : `{"instruction": "Patient asks: ...", "input": "", "output": "..."}"`
- **Volume** : ~246 000 lignes après nettoyage et déduplication
- **Prêt pour** : Fine-tuning LoRA avec Unsloth / HuggingFace PEFT