

TechCorp

INDUSTRIES · HACKATHON 2026

Rapport d'Infrastructure

Filière Infrastructure

Présenté par : ARROUD Rayan

INFRA

1 Juillet 2026

Rapport d'Infrastructure — TechCorp Industries

Filière : INFRA

Auteur : ARROUD Rayan

Date : 1 juillet 2026

1. Architecture Déployée

```
graph TD
    Internet --> VPS
    subgraph VPS_OVH [VPS OVH (51.178.48.219)]
        direction TB
        Proxy[Port 5000 → Python proxy (server.py) → Interface Web Chat]
        Ollama[Port 11434 (127.0.0.1 uniquement) → Ollama → Modèle phi3.5-financial]
    end
```

2. Services en Production

Ollama (Serveur d'Inférence)

- **Version :** 0.31.1
- **Modèle :** `phi3.5-financial:latest` (Phi-3 Mini 3.8B, Q4_0)
- **Écoute :** `127.0.0.1:11434` (accès local uniquement, sécurisé)
- **RAM utilisée :** ~4 Go sur 11 Go disponibles
- **Compute :** CPU uniquement (pas de GPU disponible)
- **Démarrage :**

```
ollama serve &
```

Interface Web (Proxy Python)

- **Port** : 5000 (accessible publiquement)
- **Fichier** : `rendu/devweb/server.py`
- **Démarrage** :

```
cd rendu/devweb && python3 server.py
```

3. Modèles Ollama Disponibles

Modèle	Taille	Description
<code>`techcorp-finance:latest`</code>	2.2 GB	Modèle principal de l'assistant financier
<code>`phi3.5-financial:latest`</code>	2.2 GB	Alias du modèle financier
<code>`phi3:latest`</code>	2.2 GB	Modèle de base (phi3 mini)
<code>`phi3.5:latest`</code>	2.2 GB	Modèle de base (phi3.5 mini)

4. Création du Modèle

Le `Modelfile` de production est à la racine du projet :

```
FROM phi3

SYSTEM """
Tu es un assistant financier expert de TechCorp Industries. Réponds toujours en français, de façon concise et professionnelle.
Si tu n'as pas accès à des données spécifiques, dis-le poliment et demande à l'utilisateur de te les fournir.
"""

PARAMETER temperature 0.3
PARAMETER num_predict 512
PARAMETER stop "<|end|>"
PARAMETER stop "<|user|>"
PARAMETER stop "<|assistant|>"
```

Commande de création :

```
ollama create techcorp-finance -f Modelfile
```

5. Sécurité

- Le port **11434 d'Ollama est fermé à l'extérieur** (bind sur 127.0.0.1)
- Seul le proxy Python (`port 5000`) est exposé publiquement
- L'adapter LoRA compromis a été désactivé (voir rapport Cyber)